

Configuración de un análisis de datos con inteligencia artificial generativa

Procesamiento de un archivo de ventas de una tienda de tecnología usando **Gemini** como herramienta de analítica: diagnóstico de calidad, limpieza, segmentación, regresión lineal y agrupamiento K-Means.

1. Datos generales de la entrega

Nombre del aprendiz	<i>Escriba aquí su nombre completo</i>
Número de documento	<i>Escriba aquí su documento</i>
Número de ficha	<i>Escriba aquí su ficha</i>
Nombre del instructor	<i>Escriba aquí el nombre del instructor</i>
Fecha de entrega	<i>DD / MM / AAAA</i>
Programa de formación	Aplicación de la inteligencia artificial en la integración de datos
Resultado de aprendizaje	220501115-02 · Procesar datos implementando herramientas de inteligencia artificial generativa, procedimiento técnico y metodología estadística
Actividad de aprendizaje	AA2 · Procesar conjuntos de datos mediante el uso de herramientas de inteligencia artificial generativa y técnicas estadísticas, según una metodología técnica definida
Evidencia	AA2-EV03 · Video configuración de analítica de datos
Herramienta de analítica	Gemini (Google) · gemini.google.com
Conjunto de datos	ventas_tienda_tecnologia.csv · 511 registros · 11 columnas
Duración del video	<i>MM minutos SS segundos</i>

2. Enlace al video

Enlace funcional al video de la evidencia:

Pegue aquí el enlace de YouTube (no listado) o Google Drive con permiso "cualquiera con el enlace puede ver"

Antes de entregar: suba la grabación de pantalla, reemplace el texto anterior por el enlace real y ábralo en una ventana de incógnito para confirmar que reproduce sin pedir permisos.

3. Justificación de la herramienta de analítica seleccionada

El archivo de ventas llega con registros duplicados por doble registro en caja, celdas vacías, montos escritos como texto con símbolo de moneda, fechas en tres formatos distintos y nombres de ciudad y categoría con mayúsculas y espacios inconsistentes. Analizarlo tal como está no es posible.

Se seleccionó **Gemini** como herramienta de analítica de datos por los criterios que se comparan a continuación:

Alternativa	Ventaja principal	Limitación frente a este caso
Hoja de cálculo (Excel)	Conocida y disponible	La limpieza es manual y no deja registro auditable de lo que se hizo
Power BI	Visualización potente	Requiere licencia por usuario para compartir el tablero
Script de Python a mano	Control total del procedimiento	Exige instalar entorno y reescribir código en cada iteración
Gemini (seleccionada)	Ejecuta Python real sobre el archivo subido, documenta cada paso en lenguaje natural y permite corregir el análisis conversando	Depende de conexión y de que la cuenta tenga habilitada la ejecución de código

Los criterios decisorios fueron: **cero instalación y cero licencia, cálculo real** (no estimado) sobre el archivo cargado, **trazabilidad** del procedimiento en lenguaje natural y **capacidad de iterar** sin reescribir el análisis desde cero.

4. Paso a paso de la configuración mostrado en el video

Ajuste los minutos de esta tabla a los de su propia grabación. Los tiempos indicados son la duración objetivo de cada etapa, no una marca fija.

Minuto	Etapla configurada	Instrucción dada a la IA
00:00 – 00:35	Presentación	Identificación del aprendiz, la ficha, el programa y la evidencia.
00:35 – 01:20	Configuración inicial	Definición del rol de analista, del trabajo por etapas y del contrato de salida: código Python visible más resultados en tablas. Carga del archivo CSV.
01:20 – 02:10	Justificación	Comparación técnica de Gemini frente a Excel, Power BI y un script de Python escrito a mano.
02:10 – 03:10	Diagnóstico de calidad	Conteo de nulos por columna, duplicados por clave, valores fuera de dominio, formatos de fecha, montos como texto y variantes de escritura.
03:10 – 04:30	Limpieza y transformación	Siete reglas en orden, cada una con el número de registros que afecta.

04:30 – 05:30	Filtros y segmentación	Segmentación por categoría y por ciudad; filtro por categoría y filtro por nivel de descuento.
05:30 – 06:40	Algoritmo supervisado	Regresión lineal simple por mínimos cuadrados.
06:40 – 07:50	Algoritmo no supervisado	Agrupamiento K-Means con $k = 3$ y estandarización z-score.
07:50 – 08:30	Conclusiones	Cinco conclusiones accionables, cada una citando una cifra del análisis.

Pegue aquí la captura de la pantalla de Gemini con el archivo cargado y la respuesta al primer prompt

Figura 1. Configuración inicial: carga del archivo y definición del rol y del contrato de salida.

5. Diagnóstico de calidad y limpieza de datos

Importante: las cifras de las secciones 5, 6 y 7 son los valores de referencia calculados sobre este mismo conjunto de datos. **Confírmelas contra lo que respondió la IA en su grabación** y reemplace cualquier número que difiera. Si la IA eligió otro criterio de imputación o de detección de atípicos, escriba el valor que le dio y mencione ese criterio: es una decisión metodológica válida, no un error.

El diagnóstico solicitado a la IA sobre los 511 registros crudos reportó:

Hallazgo	Cantidad	Detalle
Celdas vacías	69	21 en <code>precio_unitario</code> , 28 en <code>total</code> , 20 en <code>calificacion_cliente</code>
Registros duplicados	31	Mismo <code>id_venta</code> registrado dos veces
Valores fuera de dominio	9	<code>unidades</code> con signo negativo
Formatos de fecha	3	<code>YYYY-MM-DD</code> , <code>DD/MM/YYYY</code> y <code>DD-MM-YYYY</code>
Montos escritos como texto	106	<code>total</code> con símbolo de moneda y separador de miles
Variantes de escritura	14 y 10	<code>ciudad</code> (7 reales) y <code>categoria</code> (5 reales)

Sobre ese diagnóstico se aplicaron las siguientes reglas:

Regla	Técnica	Efecto medido
R1	Deduplicación por clave	31 registros repetidos eliminados · 511 → 480
R2	Normalización de texto	Espacios y mayúsculas homologados en ciudad, categoría y método de pago
R3	Conversión de tipos	\$ 1.234.500 → 1234500 ; tres formatos de fecha unificados a YYYY-MM-DD
R4	Validación de dominio	9 registros con unidades ≤ 0 eliminados · 480 → 471
R5	Tratamiento de nulos	26 registros sin datos críticos eliminados y 37 valores imputados con la mediana · 471 → 445
R6	Atípicos por rango intercuartil	56 registros por encima de $Q3 + 1,5 \cdot IQR$ (límite $\approx$ \$ 9.925.390) · 445 → 389
R7	Enriquecimiento	Columnas calculadas mes y precio_efectivo

Resultado: de **511 registros crudos** se obtuvieron **389 registros válidos**, es decir una **retención del 76,1 %** del volumen original.

Pegue aquí la captura de la tabla de limpieza generada por Gemini, con el conteo de registros por regla

Figura 2. Limpieza regla por regla con el conteo de registros afectados y la retención final.

6. Filtros, parámetros y segmentación aplicados

Sobre el conjunto limpio se segmentó por categoría y por ciudad, y luego se aplicaron dos filtros para mostrar cómo cambian los indicadores según el parámetro elegido.

Categoría	Ventas	Ingreso total	Ticket promedio	Descuento promedio
Periféricos	111	\$ 272.099.750	\$ 2.451.349	15,8 %
Computadores	30	\$ 220.941.400	\$ 7.364.713	8,2 %
Audio	96	\$ 155.904.460	\$ 1.624.005	17,6 %
Accesorios	103	\$ 86.207.310	\$ 836.964	17,6 %
Almacenamiento	49	\$ 46.701.370	\$ 953.089	20,7 %

Hallazgo de la segmentación: **Periféricos** concentra el mayor número de ventas, pero **Computadores** factura casi lo mismo con apenas 30 operaciones y el ticket promedio más alto

del portafolio. Los filtros aplicados fueron: solo categoría `Computadores` , y luego solo ventas con `descuento_pct ≥ 20` .

7. Algoritmos y técnicas de análisis implementados

7.1 Regresión lineal simple por mínimos cuadrados

Variable predictora `descuento_pct` , variable objetivo `unidades` , sobre los 389 registros válidos.

Parámetro	Valor obtenido	Interpretación
Ecuación estimada	<code>unidades = 2,0381 + 0,2210 · descuento_pct</code>	Volumen base más efecto del descuento
Pendiente (b ₁)	0,2210 unidades por punto	Cada punto de descuento agrega ~0,22 unidades vendidas
R ² (determinación)	0,7957	El descuento explica el 79,6 % de la variación en unidades
r de Pearson	0,8920	Correlación positiva fuerte
RMSE	1,15 unidades	Error típico de la predicción

Descuento	0 %	10 %	20 %	30 %	40 %
Unidades estimadas	2,04	4,25	6,46	8,67	10,88

Pegue aquí la captura del gráfico de dispersión con la recta de ajuste generado por Gemini

Figura 3. Regresión lineal: dispersión de unidades frente a descuento con la recta de ajuste.

7.2 Agrupamiento K-Means (no supervisado)

Variables `total` , `unidades` y `descuento_pct` estandarizadas con z-score, con k = 3. El algoritmo agrupó sin recibir etiquetas previas.

Cluster	Perfil comercial	Ventas	Ticket promedio	Unidades	Descuento
1	Ticket bajo, poco descuento	179	\$ 1.153.484	3,7	8,6 %
2	Volumen con descuento alto	158	\$ 1.243.073	7,9	25,6 %
3	Ticket alto (computadores)	52	\$ 7.287.983	6,0	17,8 %

*Pegue aquí la captura del gráfico de clusters
y de la tabla de perfiles generada por Gemini*

Figura 4. Segmentación K-Means en tres perfiles comerciales diferenciados.

8. Resultados y conclusiones

1. El dataset crudo **no era analizable**: 69 celdas vacías, 31 duplicados, 9 registros con unidades negativas y 106 montos escritos como texto obligaban a una limpieza previa.
2. La limpieza conservó el **76,1 %** del volumen (389 de 511 registros) con evidencia del efecto de cada regla, lo que hace el procedimiento auditable y repetible sobre el archivo de la semana siguiente.
3. El descuento es el principal impulsor del volumen: **cada punto porcentual agrega 0,22 unidades vendidas**, con $R^2 = 0,7957$. Diez puntos de descuento equivalen a ~2,2 unidades adicionales por venta.
4. La segmentación muestra una **concentración de valor**: Computadores factura \$ 220,9 millones con solo 30 ventas, mientras Accesorios necesita 103 ventas para facturar \$ 86,2 millones.
5. K-Means identificó **tres perfiles comerciales** sin etiquetas previas, lo que permite decidir por segmento: proteger el margen en el de ticket alto, y evaluar si el descuento del segmento de volumen se justifica frente al ingreso que genera.

Firma del aprendiz

Fecha de entrega

Evidencia AA2-EV03 · Video configuración de analítica de datos · Herramienta: Gemini