

Configuración de una herramienta de analítica de datos para la operación de CG CARGA

Procesamiento de los viajes exportados desde la aplicación de conductores, con limpieza, segmentación, regresión lineal y K-Means.

1. Datos generales de la entrega

Nombre del aprendiz	<i>Escriba aquí su nombre completo</i>
Número de documento	<i>Escriba aquí su documento</i>
Número de ficha	<i>Escriba aquí su ficha</i>
Nombre del instructor	<i>Escriba aquí el nombre del instructor</i>
Fecha de entrega	<i>DD / MM / AAAA</i>
Programa de formación	Aplicación de la inteligencia artificial en la integración de datos
Resultado de aprendizaje	220501115-02 · Procesar datos implementando herramientas de inteligencia artificial generativa, procedimiento técnico y metodología estadística
Actividad de aprendizaje	AA2 · Procesar conjuntos de datos mediante el uso de herramientas de inteligencia artificial generativa y técnicas estadísticas, según una metodología técnica definida
Evidencia	AA2-EV03 · Video configuración de analítica de datos
Duración del video	6 minutos 35 segundos · 1280 × 720 px · MP4 (H.264)

2. Enlace al video

Enlace funcional al video de la evidencia:

Pegue aquí el enlace de YouTube (no listado) o Google Drive con permiso "cualquiera con el enlace puede ver"

Antes de entregar: suba el archivo `AA2-EV03-configuracion-analitica.mp4`, reemplace el texto anterior por el enlace real y ábralo en una ventana de incógnito para confirmar que reproduce sin pedir permisos.

3. Justificación de la herramienta de analítica seleccionada

La aplicación de conductores de CG CARGA exporta cada semana un archivo CSV con los viajes realizados. Ese archivo llega con registros reenviados por la app, celdas vacías, montos escritos

con símbolo de moneda y fechas en tres formatos distintos, por lo que no puede analizarse directamente.

Se evaluaron cuatro alternativas y se seleccionó una **consola de analítica propia ejecutada en el navegador**, por los criterios que se resumen a continuación:

Alternativa	Ventaja	Limitación frente al caso
Hoja de cálculo (Excel)	Conocida por el equipo	La limpieza es manual y no deja registro auditable
Power BI	Visualización potente	Requiere licencia por usuario para compartir
Looker Studio	Gratuito y colaborativo	Obliga a subir datos operativos a la nube
Consola propia (seleccionada)	Reglas escritas, log de cada transformación, costo cero, ejecución local	Requiere desarrollo inicial, que ya está hecho

Los criterios decisorios fueron **reproducibilidad** (las reglas quedan escritas y no dependen de clics), **trazabilidad** (cada transformación deja evidencia en pantalla con el conteo exacto de registros afectados), **costo cero** y **portabilidad**.

4. Paso a paso de la configuración mostrado en el video

Minuto	Etapas	Qué se configura y se demuestra
00:00 – 00:44	Justificación	Problema de negocio, alternativas evaluadas y arquitectura del flujo analítico de siete etapas.
00:45 – 01:36	Configuración inicial	Origen de datos, delimitador, codificación UTF-8, granularidad mensual, campo temporal, formato de fecha, moneda COP y zona horaria.
01:37 – 02:19	Importación y perfilado	Carga de 554 registros y 12 campos; perfilado automático de nulos, duplicados, tipos inferidos y valores fuera de dominio.
02:20 – 03:23	Limpieza y transformación	Seis reglas de calidad (R1 a R6) más el enriquecimiento R7, cada una con su conteo de registros afectados.
03:24 – 04:36	Filtros y segmentación	Filtros por vehículo, estado y distancia mínima; segmentación por tipo de vehículo y ajuste del subconjunto de entrenamiento.
04:37 – 05:58	Algoritmos de análisis	Regresión lineal por mínimos cuadrados y agrupamiento K-Means con estandarización z-score.
05:59 – 06:35	Resultados	Indicadores del pipeline completo y conclusiones accionables.

CG CARGA

ANÁLITICA DE DATOS

FLUJO DE CONFIGURACIÓN

1 Justificación

2 Configuración inicial

3 Importación de datos

4 Limpieza y transformación

5 Filtros y segmentación

6 Algoritmos de análisis

7 Resultados

PASO 2 DE 7

PASO 2 · CONFIGURACIÓN INICIAL

Configuración inicial de la herramienta

Se declaran los parámetros de conexión y el contrato de datos: origen, delimitador, codificación, campo temporal, formato de fecha, moneda y granularidad de agregación.

Origen de datos

Archivo fuente (export de la app de conductores)

data/viajes_cg_carga.csv

Delimitador de campos

,

Codificación de caracteres

UTF-8

Granularidad de agregación

Mensual

Contrato de datos

Campo temporal

fecha

Formato de fecha de salida

DD/MM/YYYY

Moneda de los montos

COP (peso colombiano)

Zona horaria

America/Bogota (UTC-5)

Guardar configuración

Figura 1. Configuración inicial: origen de datos y contrato de datos (minuto 01:18 del video).

5. Importación y limpieza de datos

El perfilado de calidad, ejecutado automáticamente al importar, reportó **70 celdas vacías**, **34 identificadores duplicados** y **15 viajes con distancia negativa** sobre 554 registros crudos. Sobre ese diagnóstico se aplicaron las reglas de limpieza:

Regla	Técnica	Efecto medido
R1	Deduplicación por clave	34 registros repetidos eliminados usando <code>id_viaje</code>
R2	Normalización de texto	Espacios, mayúsculas y acentos homologados en ciudades y conductores
R3	Conversión de tipos	\$ 1.234.000 → 1234000 ; tres formatos de fecha unificados a YYYY-MM-DD
R4	Validación de dominio	14 viajes con distancia menor o igual a cero descartados
R5	Tratamiento de nulos	38 registros sin costo o distancia eliminados; 30 valores imputados con la mediana
R6	Atípicos por rango intercuartil	27 fletes por encima de $Q3 + 1,5 \cdot IQR$ retirados
R7	Enriquecimiento	Campos calculados <code>costo_por_km</code> , <code>rendimiento_km_gal</code> , <code>ruta</code> y <code>mes</code>

Resultado: de **554 registros crudos** se obtuvieron **441 registros válidos**, es decir una **retención del 79,6 %** del volumen original.



Figura 2. Reglas de calidad y registro de limpieza con el conteo exacto por regla (minuto 02:30).

6. Filtros, parámetros y segmentación aplicados

Sobre el conjunto limpio se demuestra el efecto de los parámetros de análisis. Primero se revisa el universo completo (441 viajes) y su segmentación por tipo de vehículo; luego se restringe a **tractomulas efectivamente entregadas con distancia mínima de 200 km**, lo que deja solo 34 observaciones; finalmente se libera la distancia mínima para conservar un segmento homogéneo de **56 viajes**, adecuado para ajustar un tarifario por kilómetro.

Tipo de vehículo Ciudad de origen Estado del viaje Mes inicial y final Distancia mínima



Figura 3. Filtros aplicados y recálculo inmediato de los indicadores (minuto 04:12).

7. Algoritmos y técnicas de análisis implementados

7.1 Regresión lineal simple por mínimos cuadrados

Variable predictora `distancia_km` , variable objetivo `costo_flete` , sobre las 56 observaciones del segmento de tractomulas entregadas.

Parámetro	Valor obtenido	Interpretación
Ecuación estimada	<code>costo = 1.018.912 + 5.412 · km</code>	Tarifa fija más costo variable por kilómetro
Pendiente (b_1)	\$ 5.412 por km	Tarifario base para cotizar rutas nuevas
R^2 (determinación)	0,9570	El modelo explica el 95,7 % de la variabilidad del flete
r de Pearson	0,9783	Correlación positiva muy fuerte
RMSE	\$ 243.446	Error típico de la predicción
MAE	\$ 193.209	Desviación media absoluta



Figura 4. Regresión lineal: ecuación, bondad de ajuste y errores del modelo (minuto 05:00).

7.2 Agrupamiento K-Means (no supervisado)

Variables `distancia_km` , `peso_toneladas` y `costo_flete` estandarizadas con z-score, con $k = 3$. El algoritmo convergió en 5 iteraciones con una inercia total de 68,34.

Cluster	Perfil operativo	Viajes	Km promedio	Flete promedio
1	Liviano de corta distancia	14	137 km	\$ 1.853.643
2	Pesado regional	16	224 km	\$ 2.021.063
3	Nacional de larga distancia	26	516 km	\$ 3.888.346



Figura 5. Segmentación K-Means en tres perfiles logísticos sin etiquetas previas (minuto 05:40).

8. Resultados y conclusiones

- La configuración inicial dejó la fuente tipada y homologada: fecha en formato YYYY-MM-DD, moneda en pesos colombianos y granularidad mensual, de modo que cualquier archivo nuevo de la app de conductores entra por el mismo contrato de datos.
- La limpieza recuperó el **79,6 %** del volumen original (441 de 554 registros) eliminando duplicados, nulos críticos, distancias inválidas y atípicos por rango intercuartil, con evidencia auditable de cada regla.
- La regresión lineal entrega un **tarifario base de \$ 5.412 por kilómetro** con $R^2 = 0,9570$, utilizable para cotizar rutas nuevas del segmento de tractomulas.
- K-Means identificó **tres perfiles operativos** que permiten priorizar dónde renegociar tarifas o consolidar cargas, sin necesidad de etiquetas previas.
- El tablero queda parametrizado y reproducible: el mismo flujo de siete etapas se repite sobre el archivo de la semana siguiente sin rehacer configuración.



Figura 6. Pantalla de resultados con los indicadores del proceso completo (minuto 06:20).

Firma del aprendiz

Fecha de entrega

Evidencia AA2-EV03 · Video configuración de analítica de datos · CG CARGA